




Pharmacy

Studio del profilo terapeutico e del rischio clinico dei farmaci

Alessandro Bilba, 799178
a.bilba@studenti.uniba.it

a.a. 2025/2026

link repository GitHub:
<https://github.com/albi105/Progetto-ICON-15-09-26>

Indice

1	Introduzione	2
1.1	Dominio di applicazione	2
1.2	Obiettivi	2
1.3	Strumenti utilizzati	2
2	Dataset	3
2.1	Controllo e analisi dei dati	3
2.1.1	Aree terapeutiche	3
2.1.2	Complessità della formula	4
2.1.3	Tossicità del farmaco	4
2.1.4	Variabile obiettivo e gestione data leakage	4
2.2	Analisi dei dati e visualizzazione grafica	5
3	Ontologia	6
3.1	Implementazione	6
3.2	Arricchimento dei dati	6
3.2.1	Interrogazione semantica via SPARQL	6
3.2.2	Caching semantico	7
3.2.3	Esecuzione del motore a regole deduttive	7
3.3	Risultati ottenuti	8
4	Apprendimento supervisionato	9
4.1	K-Nearest Neighbors	9
4.2	Regressione logistica	9
4.3	Decision tree	9
4.4	Random forest	9
4.5	Analisi degli iperparametri	9
4.6	Deep learning : Multilayer perceptron	10
4.7	Studio bias-varianza e regolarizzazione	10
5	Modelli probabilistici	12
5.0.1	Definizione del grafo	12
5.1	Stima dei parametri	12
5.2	Simulazione di scenari	12
5.2.1	Monoterapia per problemi cardiovascolari	13
5.2.2	Multicomponente con tossicità alta	13
5.2.3	Terapia oncologica con alta tossicità	13
5.3	Inferenza retrograda	14
5.4	Apprendimento strutturale del grafo (Structure Learning)	14
6	Conclusioni e sviluppi futuri	17
6.1	Sviluppi futuri	17

1 Introduzione

1.1 Dominio di applicazione

Nel settore sanitario e farmacologico, l'efficacia di una terapia e l'aderenza del paziente non dipendono solo dalle proprietà biologiche e chimiche dei principi attivi, ma da un'interazione di diverse caratteristiche cliniche. In particolare, l'area di intervento della terapia, la complessità (se si tratta di *monoterapia* o *politerapia*) e il profilo di tollerabilità sistemica (le reazioni avverse dei medicinali). Molti dati esistenti nei database clinici si presentano sotto forma di testi eterogenei, non standardizzati e strutturati solo parzialmente, di conseguenza i sistemi sono fortemente limitati, in quanto molto spesso si tratta di sistemi statistici il cui scopo è cogliere le relazioni causali e le dipendenze di rischio, rendendo necessaria l'integrazione di modelli basati sulla conoscenza formale (Knowledge-Based Systems, KBS).

1.2 Obiettivi

L'obiettivo del progetto è la progettazione, l'implementazione e la validazione di una KBS orientata alla modellazione della conoscenza farmacologica, alla valutazione del rischio clinico e alla predizione del successo del trattamento terapeutico. Il sistema utilizza un campione reale di 11825 medicinali e si articola in quattro elementi principali:

- **Web semantico:** la conoscenza terminologica è stata formalizzata attraverso lo standard W3C, definendo gerarchie tassonomiche, vincoli di disgiunzione e profili di vigilanza di sfondo.
- **Motore inferenziale:** il grafo semantico è stato interrogato ed è stato utilizzato un motore a regole condizionali affinché i dati grezzi vengano arricchiti con nuovi attributi ottenuti (*Drug Complexity, Toxicity Tier, Clinical Risk, Treatment Viability*).
- **Apprendimento supervisionato:** valutazione dei modelli su 10 run indipendenti con convalida incrociata (GridSearchCV) per fare un confronto tra l'utilizzo dei dati grezzi e dei dati arricchiti semanticamente, soffermandosi sul trade-off bias-varianza.
- **Modelli probabilistici (reti bayesiane):** utilizzo di un grafo aciclico diretto (DAG) per la gestione dell'incertezza. Si fa riferimento all'inferenza esatta (con l'uso di *Variable Elimination*) e alla diagnostica inversa, implementando anche una procedura di apprendimento della struttura (*Hill-Climb Search*) per confrontare ciò che viene progettato dall'esperto di dominio e le relazioni estratte in modo autonomo dai dati.

1.3 Strumenti utilizzati

Gli strumenti utilizzati per la progettazione e lo sviluppo del sistema sono:

- **Google Colab e Python:** ambiente di calcolo integrato per l'esecuzione del codice, verifica dei parametri e riproducibilità dei risultati.
- **RDFLib:** framework per il web semantico utilizzato per la formalizzazione della TBox (classi, assiomi di disgiunzione e properties), l'istanziatura della ABox e l'esecuzione delle query in sintassi SPARQL.
- **Scikit-Learn:** libreria per l'apprendimento automatico utilizzata nella gestione dei campioni (train e test), nella selezione delle feature continue (*StandardScaler*), nell'ottimizzazione degli iperparametri e nella valutazione delle metriche per K-NN, Regressione Logistica, Decision Tree, Random Forest e Multilayer Perceptron (MLP).
- **Pgmpy:** libreria specializzata in modelli grafici probabilistici, utilizzata per la definizione del DAG, la stima a massima verosimiglianza delle tabelle di probabilità condizionata, la risoluzione dei quesiti d'inferenza attraverso *Variable Elimination* e l'apprendimento strutturale del grafo tramite *HillClimbSearch*.
- **Pandas e NumPy:** strumenti per la manipolazione dei dati, pulizia dei campi testuali, estrazione delle feature e calcolo delle distribuzioni aggregate.
- **Matplotlib e Seaborn:** librerie grafiche utilizzate per la generazione delle curve di convergenza della loss, di grafici per il trade-off bias-varianza e delle distribuzioni delle probabilità a posteriori.

2 Dataset

Il dataset impiegato per lo sviluppo del sistema è `Medicine_Details.csv`, presente su [Kaggle](#), che comprende un totale di 11825 record relativi a preparazioni medicinali commercializzate. Essi sono descritti mediante 9 attributi eterogenei, che coprono le caratteristiche commerciali, cliniche, formulative e di riscontro da parte dei pazienti:

1. **Medicine Name**: nome commerciale del prodotto farmaceutico, comprendente anche il dosaggio e via di somministrazione (es. *Avastin 400mg Injection*, *Augmentin 625 Duo Tablet*).
2. **Composition**: indica qualità e quantità dei principi attivi presenti, con le relative concentrazioni unitarie.
3. **Uses**: indicazioni terapeutiche e target patologico per cui il farmaco è prescritto o approvato.
4. **Side_effects**: elenco testuale non strutturato delle reazioni avverse ed effetti collaterali associati all'assunzione del farmaco.
5. **Image URL**: percorso dell'immagine identificativa della confezione.
6. **Manufacturer**: denominazione del titolare dell'autorizzazione all'immissione in commercio o dell'azienda farmaceutica produttrice (759 produttori distinti nel campione).
7. **Excellent Review %**: percentuale di valutazioni eccellenti espresse dagli utilizzatori (valore continuo intero compreso tra 0 e 100).
8. **Average Review %**: percentuale di valutazioni medie registrate (da 0 a 88).
9. **Poor review %**: percentuale di valutazioni negative o di insuccesso percepito riportate dall'utenza (da 0 a 100).

```
ANALISI QUALITATIVA E STRUTTURALE DEL CORPUS CLINICO
-> Dimensione totale del campione:          11,825 record
-> Valori nulli rilevati (su tutte le colonne): 0 (Integrità 100%)
-> Record interamente duplicati (lotti):      84 (~0.71%)
-> Specialità farmaceutiche univoche:         11,498
-> Produttori farmaceutici distinti:         759
```

Figura 1: Composizione dei dati

2.1 Controllo e analisi dei dati

Un'indagine in fase iniziale non ha evidenziato valori nulli, tuttavia sono stati identificati 84 record interamente duplicati, i quali sono stati gestiti preservando la consistenza statistica. La principale criticità del dataset è l'alta variabilità e la non standardizzazione dei campi testuali `Uses`, `Composition` e `Side_effects`. Essi si presentano sotto forma di stringhe non normalizzate. Per risolvere questo problema, è stata svolta una fase di miglioramento semantico e strutturale per evitare di ricorrere a tecniche più complesse come NLP:

2.1.1 Aree terapeutiche

La colonna `Uses` comprendeva oltre 700 stringhe uniche, composte da una serie di indicazioni cliniche senza separatori espliciti. Attraverso un parser di dominio basato sul vocabolario medico, ogni record è stato mappato all'interno di 11 macroaree standard:

- *Cardiovascular* (2.128 record): patologie dell'apparato cardiovascolare, ipertensione, insufficienza cardiaca, angina, profilassi post-infarto.
- *Infectious_Diseases* (2.025 record): infezioni batteriche, micotiche, virali e parassitarie.
- *Pain_and_Inflammation* (1.698 record): sindromi dolorose acute/croniche, stati febbrili, patologie artritiche e infiammatorie.
- *General_Medicine* (1.728 record): trattamenti aspecifici o polivalenti.

- *Endocrine_Metabolic* (1.121 record): diabete mellito di tipo 2, disfunzioni tiroidee e regolazione ormonale.
- *Respiratory_and_Allergy* (890 record): asma bronchiale, broncopneumopatia cronica ostruttiva (COPD), riniti e reazioni allergiche.
- *Neuro_Psychiatry* (814 record): disturbi dell'umore, psicosi, epilessia, neuropatie centrali e periferiche.
- *Gastrointestinal* (753 record): reflusso gastroesofageo, malattia da ulcera peptica, disturbi della motilità.
- *Dermatology, Ophthalmology, Oncology* (somma: 668 record): aree specialistiche ad alto rigore terapeutico o d'organo.

2.1.2 Complessità della formula

La politerapia e determinate associazioni a dose fissa possono aumentare il rischio di interazioni farmacologiche rispetto alle monoterapie. Analizzando la colonna **Composition**, il sistema separa i preparati attraverso il delimitatore +:

- **Mono_component**: (7.069 record, 59.8%): farmaci formulati con un singolo principio attivo.
- **Multi_component**: combinazioni a dosaggio fisso contenenti due o più molecole attive.

2.1.3 Tossicità del farmaco

L'elenco di effetti avverso è stato processato estraendo il numero di reazioni e problematiche dichiarate, attraverso tokenizzazione su pattern maiuscolo-minuscolo. L'indice risultante è stato poi suddiviso in fasce di tollerabilità:

- **Low_Toxicity** (2.383 record): farmaci con non più di 3 reazioni avverse dichiarate o ad uso topico/locale.
- **Moderate_Toxicity** (5.171 record): preparazioni che riportano tra 4 e 7 effetti collaterali noti.
- **High_Toxicity** (4.271 record): trattamenti ad alto impatto sistemico con oltre 7 manifestazioni avverse documentate.

2.1.4 Variabile obiettivo e gestione data leakage

La variabile target da predire per le fasi di classificazione e per il DAG bayesiano è **Target_success**:

$$\text{Target_Success} = \begin{cases} 1 & \text{se Excellent Review \%} \geq 38 \quad \wedge \quad \text{Poor Review \%} \leq 28 \\ 0 & \text{altrimenti} \end{cases}$$

Questa soglia garantisce un campione bilanciato, dove gli elementi appartenenti alla classe 0 sono 7013 (59,31%) mentre quelli appartenenti alla classe 1 sono 4812 (40,96%). Nelle fasi successive di apprendimento supervisionato, tutte e tre le colonne relative alle recensioni (**Excellent Review %**, **Average Review %**, **Poor Review %**) sono state rigorosamente escluse dalla matrice delle feature predittive (\$X\$). Utilizzare metriche di recensione per predire una variabile target derivata dalle stesse recensioni avrebbe introdotto una correlazione spuria.

2.2 Analisi dei dati e visualizzazione grafica

L'analisi esplorativa del dataset ha permesso di comprendere meglio come si distribuiscono le caratteristiche dei farmaci e di verificare la solidità delle scelte fatte per la preparazione dei dati, come illustrato nella panoramica grafica a quattro quadranti (Figura 2). Dal punto di vista delle valutazioni degli utenti, i giudizi mostrano un andamento piuttosto asimmetrico: le recensioni positive si attestano in media attorno al 38,5%, mentre quelle negative si aggirano sul 25,7%, a conferma del fatto che la soglia logica scelta per definire la variabile del successo terapeutico permette di separare in modo equilibrato i casi positivi da quelli negativi senza creare sbilanciamenti estremi. Osservando invece le reazioni avverse e la composizione dei medicinali, emerge una netta polarizzazione tra le diverse specialità mediche: aree cliniche particolarmente delicate come l'oncologia, la neuro-psichiatria e la cardiologia presentano un numero medio di effetti collaterali molto più alto rispetto a settori più mirati o a basso impatto sistemico come la dermatologia o l'oftalmologia. Infine, la complessità formulativa è legata alle esigenze della cura: le associazioni a dose fissa con più principi attivi sono frequenti soprattutto nei trattamenti per problemi respiratori, allergie e dolori acuti, mentre le terapie a singolo componente continuano a rappresentare la maggior parte delle preparazioni destinate al controllo delle infezioni e dei disturbi neurologici.




Figura 2: Grafici relativi all'analisi dei dati

3 Ontologia

Un'ontologia è una rappresentazione esplicita, formale e condivisa di una concettualizzazione di un dominio di interesse, in cui si evidenzia il significato semantico e le relazioni esistenti attraverso logiche descrittive (DL), strutturato in una componente terminologica (TBox) e una asserzionale (ABox). In questo progetto, l'implementazione dell'ontologia farmacologica mediante gli standard W3C del Web Semantico (RDF, RDFS e OWL) ha lo scopo di fornire al sistema una conoscenza di fondo (*Background Knowledge*, BK) solida e strutturata. Questo formalismo permette di superare i limiti dell'apprendimento basato sui soli dati grezzi: il sistema acquisisce la capacità di ragionare sul significato clinico dei trattamenti, deducendo nuove feature ad alto valore informativo che guidano con maggiore efficacia le successive fasi di classificazione supervisionata e di inferenza probabilistica.

3.1 Implementazione

L'ontologia è stata sviluppata in ambiente Python sfruttando la libreria `rdflib`, incapsulando il vocabolario concettuale all'interno del namespace personalizzato: <http://www.semanticweb.org/uniba/icon/pharma#>. A livello di **TBox** sono state definite le classi primarie per categorizzare le dimensioni più importanti del farmaco:

- **TherapeuticArea**: classe radice utilizzata per raggruppare le specialità mediche d'intervento, specializzata tramite la relazione `rdfs:subClassOf` nelle sottoclassi `CardiovascularArea`, `InfectiousArea`, `EndocrineMetabolicArea`, `PainInflammationArea`, `NeuroPsychiatryArea`, `OncologyArea` e `GeneralArea`.
- **DrugFormulation**: classe che descrive la composizione del medicinale, specializzata nelle due classi figlie `MonoComponent` e `MultiComponent`. Per garantire un senso logico, tra queste due sottoclassi è stato introdotto un assioma di disgiunzione esplicita (`owl:disjointWith`), formalizzando il vincolo secondo cui una formulazione non può essere contemporaneamente a singolo principio e un'associazione fissa.
- **ClinicalRiskProfile**: modella i livelli di cautela terapeutica preventivi (`LowRisk`, `ModerateRisk`, `HighRisk`).

Sono state anche definite le proprietà binarie che collegano i concetti tra loro:

- **Object Properties**: `hasRiskProfile` (relazione concettuale tra una macro-area terapeutica e il profilo di rischio clinico tipico del suo trattamento).
- **Datatype Properties**: `recommendedSafetyCheck` (collega l'area clinica a una stringa descrittiva di tipo `xsd:string` che specifica il protocollo di sorveglianza raccomandato, come il monitoraggio pressorio o glicemico).

La **ABox** è stata popolata istanziando le linee guida di riferimento clinico. Per ciascuna specialità medica è stato generato un individuo ontologico (es. `Area_Cardiovascular`, `Area_Oncology`), associandovi il relativo profilo di rischio intrinseco e la tipologia di controllo preventivo richiesto. L'intero grafo semantico risultante è stato validato e serializzato su file standard RDF/XML (`pharma_ontology.rdf`).

3.2 Arricchimento dei dati

L'arricchimento dei dati prevede l'integrazione della conoscenza formalizzata nell'ontologia con i dati grezzi memorizzati nel `DataFrame`, il tutto articolato in tre fasi.

3.2.1 Interrogazione semantica via SPARQL

Il grafo RDF viene interrogato tramite una query standard SPARQL per estrarre le relazioni associative definite a livello di sfondo. La query recupera per ogni area terapeutica il corrispondente profilo di rischio suggerito e il protocollo di verifica associato:

```
PREFIX pharma: <http://www.semanticweb.org/uniba/icon/pharma#>
SELECT ?area ?risk ?check
WHERE {
    ?area pharma:hasRiskProfile ?risk .
    ?area pharma:recommendedSafetyCheck ?check .
}
```

3.2.2 Caching semantico

Le tuple restituite dalla query SPARQL vengono deserializzate e indicizzate all'interno di una struttura a dizionario ad accesso rapido denominata `kb_guidelines`. Questa operazione associa a ciascuna macro-area testuale il suo profilo logico ontologico, ottimizzando le prestazioni computazionali e azzerando la latenza di lettura sul grafo durante il ciclo di scansione.

3.2.3 Esecuzione del motore a regole deduttive

Il sistema cicla sui record del dataset grezzo e valuta un insieme di regole di produzione condizionali (*If-Then*) che combinano le feature estrattive (`Drug_Complexity` e `Toxicity_Tier`) con le regole ereditate dall'ontologia:

- **Clinical Risk (Rischio Clinico)**: valuta la criticità terapeutica complessiva della preparazione medicinale. Il farmaco viene assegnato a `High_Risk` qualora appartenga a un'area clinica vincolata ad alta vigilanza (come oncologia o neuro-psichiatria) oppure nel caso in cui sia una combinazione fissa (`Multi_Component`) associata a un carico tossicologico elevato (`High_Toxicity`). Viene invece etichettato come `Moderate_Risk` nel caso in cui presenti tossicità intermedia o appartenga ad aree croniche cardiometaboliche, e `Low_Risk` se si tratta di una monoterapia ben tollerata.
- **Treatment Viability (Viabilità Terapeutica)**: stima la sicurezza d'uso generale del trattamento, assegnando il valore `High_Viability` ai farmaci a basso rischio con ridotta tossicità, e `Guarded_Viability` ai preparati a rischio elevato che richiedono stretto monitoraggio medico.

L'esito di questa fase è la generazione del dataset consolidato `pharma_enriched.csv`, il quale integra dati descrittivi di partenza e conoscenza dedotta dal sistema a regole, fornendo una matrice ottimizzata per la classificazione e la modellazione bayesiana.

Tabella 1: Campione del dataset: feature grezze principali

Medicine Name	Composition	Uses	Exc%	Avg%	Poor%
Avastin 400mg	Bevacizumab (400mg)	Cancer of colon/rectum	22	56	22
Augmentin 625	Amoxycillin + Clav. Acid	Bacterial infections	47	35	18
Azithral 500	Azithromycin (500mg)	Bacterial infections	39	40	21
Ascoril LS Syrup	Ambroxol + Levosalbutamol	Cough with mucus	24	41	35
Aciloc 150	Ranitidine (150mg)	Gastroesophageal reflux	34	37	29

Tabella 2: Campione del dataset: feature semantiche e target derivati

Medicine Name	Therapeutic Area	Complexity	Toxicity	Count	Target	Clinical Risk	Viability
Avastin 400mg	Oncology	Mono	High	9	0	High Risk	Guarded
Augmentin 625	Infectious Diseases	Multi	Moderate	4	1	Moderate Risk	Standard
Azithral 500	Infectious Diseases	Mono	Low	3	1	Low Risk	High
Ascoril LS Syrup	Respiratory/Allergy	Multi	High	14	0	High Risk	Guarded
Aciloc 150	Gastrointestinal	Mono	Low	3	0	Low Risk	High

3.3 Risultati ottenuti

Per evidenziare la differenza che l'introduzione della conoscenza ha portato, è stata calcolata una tabella di contingenza incrociando la feature logica `Clinical_Risk` con la variabile obiettivo reale `Target_Success`:

Tabella 3: Tabella di contingenza tra Rischio Clinico dedotto e Target Success.

Livello Rischio Clinico	Insuccesso (Target = 0)	Successo (Target = 1)	Totale Farmaci
Basso Rischio (Low)	863 (65.08%)	463 (34.92%)	1.326
Rischio Moderato (Moderate)	4.787 (60.68%)	3.102 (39.32%)	7.889
Alto Rischio (High)	1.363 (52.22%)	1.247 (47.78%)	2.610

Dall'incrocio emerge come la regola semantica riesca a polarizzare il campione: mentre i farmaci classificati a basso rischio comprendono prevalentemente prodotti da banco o formulazioni generiche a percezione di impatto più moderata, le preparazioni ad alto rischio clinico (spesso terapie salvavita o trattamenti specialistici combinati) mostrano una quota di successo e soddisfazione significativamente più alta (47.78%), riflettendo la percezione di efficacia terapeutica indispensabile nei pazienti con quadri clinici complessi.

A differenza di euristiche basate direttamente sui giudizi degli utenti che rischierebbero di causare fenomeni di Data Leakage, questa classificazione è stata dedotta combinando unicamente la natura chimica della composizione, la macro-area terapeutica e le linee guida dell'ontologia.




Figura 3: Analisi di correlazione tra la feature dedotta dall'ontologia (`Clinical_Risk`) e la variabile obiettivo (`Target_Success`). A sinistra: mappa di calore con i conteggi assoluti di contingenza. A destra: composizione percentuale condizionata per riga che evidenzia la crescita del tasso di successo al crescere del rischio clinico.

Per confermare che questa correlazione sia reale e non frutto del caso, è stato eseguito il test d'indipendenza del Chi-quadro. Il test ha restituito un valore di $\chi^2 = 78.77$ ($p < 10^{-16}$, con 2 gradi di libertà) e un indice V di Cramér pari a 0.082, respingendo l'ipotesi di indipendenza statistica tra le due variabili. Questo scarto percentuale (dal 34.92% dei farmaci a basso rischio fino al 47.78% di quelli ad alto rischio) dimostra l'effetto discriminante della conoscenza introdotta, che fornirà ai modelli di classificazione e alla rete bayesiana un contesto logico solido per le predizioni.

4 Apprendimento supervisionato

La fase di apprendimento supervisionato si occupa della costruzione e del confronto di modelli di classificazione capaci di prevedere l'efficacia e la soddisfazione dell'uso di un dato farmaco (**Target_Success**), sfruttando le caratteristiche cliniche e formulari. In questo caso, si è voluta evidenziare la differenza tra l'uso dei soli dati grezzi e l'uso dei dati arricchiti grazie all'ontologia:

1. nel caso dei **dati grezzi**, vengono inclusi solo i dati di partenza del farmaco, in particolare il conteggio numerico degli effetti collaterali (**Side_Effects_Count**) e le lunghezze dei testi descrittivi (**Name_Length**, **Composition_Length**, **Uses_Length**)
2. nel caso dei **dati arricchiti**, vengono aggiunte altre informazioni, quelle ottenute dall'ontologia ((**Therapeutic_Area**, **Drug_Complexity**, **Toxicity_Tier**, **Clinical_Risk**, **Treatment_Viability**)), trasformate in variabili binarie tramite One-Hot Encoding per garantirne l'indipendenza.

Per evitare fenomeni di *data leakage*, tutte le percentuali originali delle recensioni sono state escluse dalle variabili di input X. In questo modo, l'algoritmo si concentra solo sulle caratteristiche oggettive del farmaco e sulla conoscenza inserita nel sistema. La valutazione è stata condotta su **10 run indipendenti** con partizionamento del dataset in 80% per l'addestramento e il 20% per il test. Il partizionamento è stratificato, per evitare una casualità nel campionamento. Su ogni run, i parametri dei modelli sono stati sintonizzati mediante **GridSearchCV con 3-fold Cross-Validation**, massimizzando la metrica dell'F1-Score per bilanciare precisione e richiamo.

4.1 K-Nearest Neighbors

L'algoritmo K-NN decide la classe di appartenenza in base alla vicinanza geometrica nello spazio delle variabili. Essendo sensibile alla differenza di scala tra feature numeriche e variabili dummy binarie, è stato applicato uno **StandardScaler** calcolato solo sul set di addestramento e trasferito sul test. La ricerca ha esplorato valori di vicinato K in 3, 5, 7. Nello scenario arricchito (+KB), l'algoritmo sfrutta i raggruppamenti creati dalle classi di rischio ontologiche, ottenendo confini di decisione più chiari e stabili.

4.2 Regressione logistica

La regressione logistica fornisce una misura di probabilità per la classificazione binaria comprimendo la combinazione lineare delle variabili attraverso la funzione sigmoide. La griglia dei parametri ha valutato diversi valori di regolarizzazione inversa C in 0.1, 1.0, 10.0 con un limite di iterazioni fissato a 500 per assicurare la convergenza numerica. I vettori di input sono stati preventivamente standardizzati a media zero e varianza unitaria.

4.3 Decision tree

L'Albero di Decisione suddivide lo spazio dei dati tramite una gerarchia di test condizionali, selezionando le partizioni ottimali in base all'indice di impurità di Gini. Per controllare la complessità della struttura ed evitare l'overfitting, la ricerca ha calibrato la profondità massima esplorando **max_depth** in 3, 5, 10. Non richiedendo normalizzazione dei dati, l'albero è stato addestrato direttamente sulle feature originali, sfruttando fin dai primi nodi le etichette logiche introdotte dall'ontologia.

4.4 Random forest

Il Random Forest è un modello ensemble basato sul principio del *bagging*, che aggrega le decisioni di molteplici alberi indipendenti addestrati su sottoinsiemi casuali di dati e feature. La ricerca ha analizzato combinazioni sul numero di stimatori (**n_estimators** in 50, 100) e sui limiti di crescita in profondità. La struttura a foresta ha permesso di cogliere relazioni non lineari articolate tra l'area terapeutica d'organo e la complessità di associazione del farmaco.

4.5 Analisi degli iperparametri

La procedura automatica di Grid Search ha evidenziato una convergenza costante dei parametri lungo le 10 run:

- **K-NN**: ha preferito valori bassi di vicinato ($K = 3$ o $K = 5$), a riprova del fatto che la presenza di cluster semantici definiti richiede confini di separazione locali e poco dispersi.

- **Logistic Regression:** si è stabilizzata su $C = 10.0$ nello scenario arricchito (+KB), consentendo ai pesi delle nuove variabili dedotte di esprimere il loro pieno contributo logico.
- **Modelli ad albero:** il Decision Tree ha ottenuto la migliore generalizzazione fissando la profondità massima a `max_depth = 5`, evitando il rumore dei dettagli testuali presenti a livelli più profondi. Il Random Forest ha conseguito le prestazioni più alte con 100 alberi e profondità vincolata a 10, coniugando stabilità e capacità predittiva.

Esecuzione su 10 Run indipendenti...

TABELLA COMPARATIVA 10 RUN CON MEDIA E DEVIAZIONE STANDARD

Modello	Accuratezza (Grezzo)	Accuratezza (+KB)	F1-Score (Grezzo)	F1-Score (+KB)
K-NN	57.63% $\pm$ 0.80	59.03% $\pm$ 0.54	45.51% $\pm$ 1.39	46.61% $\pm$ 0.68
Logistic Regression	58.78% $\pm$ 0.34	62.05% $\pm$ 0.69	5.45% $\pm$ 0.64	40.12% $\pm$ 0.84
Decision Tree	61.05% $\pm$ 0.70	61.78% $\pm$ 0.85	41.03% $\pm$ 1.40	41.26% $\pm$ 1.49
Random Forest	58.60% $\pm$ 0.98	59.11% $\pm$ 1.18	45.88% $\pm$ 1.21	47.03% $\pm$ 1.38

Figura 4: Risultati dell'addestramento

L'aspetto più rilevante riguarda il comportamento della Regressione Logistica: sui dati grezzi il modello presentava un F1-Score di appena il **5.45%**, poiché le sole lunghezze del testo e il conteggio degli effetti non fornivano una separazione lineare sufficiente per riconoscere la classe positiva. Con l'integrazione delle feature semantiche (+KB), l'F1-Score sale al **40.12%** (un balzo netto di circa +35%), fornendo un piano discriminante concreto. Inoltre, la ridotta deviazione standard riscontrata su tutti i test (sempre compresa tra lo 0.5% e l'1.6%) certifica che i miglioramenti derivano dalla qualità della base di conoscenza e non da oscillazioni casuali dei dati.

4.6 Deep learning : Multilayer perceptron

Per estendere ulteriormente il sistema, è stata implementata una rete neurale artificiale feed-forward di tipo Multilayer Perceptron (MLP). L'architettura è composta da due strati nascosti densi (da 32 e 16 neuroni) con funzione di attivazione non lineare ReLU ($\max(0, z)$). L'aggiornamento dei pesi è guidato dall'algoritmo di retropropagazione con ottimizzatore *Adam*, regolarizzazione L_2 ($\alpha = 0.01$) e meccanismo di *Early Stopping* per bloccare l'addestramento non appena la loss di validazione cessa di diminuire. L'analisi della funzione di costo mostra che l'arricchimento semantico accelera notevolmente la convergenza della rete: nello scenario arricchito (+KB), l'architettura raggiunge un valore finale di loss inferiore e una curva di discesa più rapida rispetto allo scenario grezzo, provando che la presenza di concetti astratti facilita l'ottimizzazione dei pesi.




Figura 5: Convergenza della loss MLP

4.7 Studio bias-varianza e regolarizzazione

E' stata condotta un'analisi dedicata al compromesso bias-varianza e al comportamento delle tecniche di regolarizzazione utilizzate (Lasso e Ridge).

- **Trade-off bias-varianza nell'albero decisionale:** variando l'altezza massima dell'albero tra 1 e 16, l'F1-Score sui dati di addestramento continua a crescere fino a oltre l'85%, mentre




Figura 6: Trade-off e regolarizzazione

sui dati di test raggiunge il picco a profondità 5 per poi calare. Questa divaricazione rappresenta l'insorgere del sovradattamento (*overfitting*): oltre una certa profondità, l'albero memorizza il rumore specifico del train set, perdendo capacità di generalizzare sui casi nuovi.

- **Confronto tra regolarizzazione L_1 e L_2 :** analizzando la risposta della Regressione Logistica al variare del parametro C , la penalità L_1 (**Lasso**) azzerava i pesi delle feature secondarie o poco informative, operando una vera e propria selezione automatica che fa risalire l'F1-Score appena $C \geq 0.1$. Al contrario, la penalità L_2 (**Ridge**) mantiene tutte le variabili attive comprimendone l'ampiezza verso lo zero, risultando più stabile nelle zone a forte penalità iniziale.

5 Modelli probabilistici

Nelle decisioni terapeutiche reali, le relazioni tra patologie, tollerabilità e risposta clinica sono stocastiche, in quanto uno stesso trattamento può avere esiti differenti in base al profilo del paziente e a fattori fisiologici che spesso non sono osservabili. Per formalizzare questo livello di incertezza, è stata implementata una **rete bayesiana** (con l'uso di `pgmpy`), che permette di superare la rigidità logica binaria grazie a due componenti principali. In primo luogo, la **struttura a grafo casuale (DAG)**, ossia una rete orientata aciclica, permette di modellare le dipendenze condizionate e le direzioni di causa-effetto stabilite dalla conoscenza di dominio. Per quanto riguarda **distribuzione di probabilità condizionata**, invece, le matrici quantitative relative all'intero campione, ottenute tramite stima a massima verosimiglianza (*Maximum Likelihood Estimation*, MLE), fungono da base per interrogazioni probabilistiche esatte.

5.0.1 Definizione del grafo

Prima della fase di progettazione del grafo, le variabili sono state discretizzate in etichette testuali esplicite (inserite in `df_bayes`) affinché possano essere utilizzate dalla libreria `pgmpy`. La topologia del DAG è stata definita riflettendo i vincoli di generazione del rischio di un medicinale:

- **Nodi radice (origini causali):** `Therapeutic_Area` (la specialità medica della patologia) e `Drug_Complexity` (la tipologia di formulazione, mono o multi-componente) confluiscono verso il nodo intermedio `Clinical_Risk`. Questa scelta riflette l'evidenza clinica secondo cui il livello di rischio iniziale di un trattamento dipende dall'apparato interessato e dall'eventuale presenza di associazioni politerapiche.
- **Nodo convergente (esito clinico):** il rischio terapeutico preventivo (`Clinical_Risk`) e il carico effettivo di reazioni avverse (`Toxicity_Tier`) puntano congiuntamente al nodo foglia `Target_Success`. L'efficacia percepita dal paziente dipende sia dal profilo di sicurezza intrinseco sia dalla severità dei disturbi manifestati durante l'assunzione.




Figura 7: Struttura del grafo probabilistico ad albero (DAG)

La funzione `model.check_model()` ha confermato la validità della rete, accertando l'assenza di cicli diretti e la consistenza delle dimensioni probabilistiche.

5.1 Stima dei parametri

Definita l'architettura del grafo, le tabelle di probabilità condizionata sono state parametrizzate attraverso lo stimatore di massima verosimiglianza. Per le variabili radice, la CPT registra le probabilità a priori del mercato farmaceutico analizzato (ad esempio la frequenza relativa delle preparazioni mono-principio pari a circa il 59.8% rispetto alle associazioni fisse al 40.2%). Per i nodi figli, la CPT memorizza le probabilità condizionate di ogni configurazione possibile dei genitori, calcolando la distribuzione dell'esito clinico per ogni combinazione di rischio e tossicità. L'algoritmo di **Variable Elimination** si occupa della risoluzione delle interrogazioni, rimuovendo i nodi non influenti rispetto all'evidenza fornita.

5.2 Simulazione di scenari

Date particolari condizioni specifiche impostate come evidenze note, il motore inferenziale calcola la probabilità a posteriori che il trattamento si traduca in successo clinico $P(\text{Target_Success} | e)$, simulando in particolare 3 profili rappresentativi.

5.2.1 Monoterapia per problemi cardiovascolari

Questo profilo esamina un farmaco per disturbi circolatori formulato con una singola molecola attiva e caratterizzato da un carico ridotto di effetti avversi.

```
=====
SCENARIO 1: Monoterapia Cardiovascolare a Bassa Tossicità
=====
+-----+-----+
| Target_Success | phi(Target_Success) |
+-----+-----+
| Target_Success(0) | 0.6220 |
+-----+-----+
| Target_Success(1) | 0.3780 |
+-----+-----+
```

Figura 8: Primo caso

Sebbene il farmaco presenti un profilo di sicurezza controllato, la probabilità di successo rispecchia la difficoltà tipica delle terapie croniche, dove l'assenza di sintomi immediati porta spesso a una ridotta percezione di beneficio tangibile da parte del paziente rispetto a trattamenti sintomatici rapidi.

5.2.2 Multicomponente con tossicità alta

In questo caso, la presenza di più principi attivi spinge la probabilità di successo al 41.62% (superiore a quella del caso 1). Questo apparente paradosso rispecchia le dinamiche terapeutiche in cui le associazioni fisse vengono impiegate per contrastare patologie severe e resistenti: l'efficacia dell'azione combinata viene riconosciuta positivamente dall'utilizzatore, pur dovendo sopportare un carico di tossicità non trascurabile.

```
=====
SCENARIO 2: Politerapia (Multi-Drug) ad Alta Tossicità
=====
+-----+-----+
| Target_Success | phi(Target_Success) |
+-----+-----+
| Target_Success(0) | 0.5838 |
+-----+-----+
| Target_Success(1) | 0.4162 |
+-----+-----+
```

Figura 9: Secondo caso

5.2.3 Terapia oncologica con alta tossicità

La rete attribuisce a questa configurazione la percentuale di successo più alta (47.98%). La motivazione risiede nella natura salvavita della cura: in oncologia la comparsa di disturbi collaterali severi è considerata un costo accettabile rispetto all'arresto della progressione tumorale, con conseguenti valutazioni di forte gradimento terapeutico.

```
=====
SCENARIO 3: Trattamento Oncologico ad Alta Sorveglianza
=====
```

Target_Success	phi(Target_Success)
Target_Success(0)	0.5202
Target_Success(1)	0.4798

```
=====
```

Figura 10: Terzo caso

5.3 Inferenza retrograda

Sfruttando le caratteristiche di questi modelli grafici, il motore inferenziale è in grado di effettuare un ragionamento deduttivo, cioè dato l'esito clinico è possibile risalire lungo le dipendenze del grafico alla configurazione maggiormente compatibile con l'evidenza. In particolare, il motore è stato interrogato per analizzare il profilo dei trattamenti che hanno registrato un insuccesso terapeutico:

```
res_diag = infer.query(variables=['Clinical_Risk'], evidence={'Target_Success': '0'})
```

```
=====
DIAGNOSTICA INVERSA: Rischio Clinico dato l'Insuccesso Terapeutico (Target=0)
=====
```

Clinical_Risk	phi(Clinical_Risk)
Clinical_Risk(High_Risk)	0.1699
Clinical_Risk(Low_Risk)	0.1016
Clinical_Risk(Moderate_Risk)	0.7285

```
=====
```

Figura 11: Risultati ottenuti dalla diagnostica inversa

L'algoritmo di Eliminazione di Variabile marginalizza le variabili non osservate e restituisce la seguente distribuzione di probabilità a posteriori:

- Clinical_Risk(Moderate_Risk) : 72.85%
- Clinical_Risk(High_Risk) : 16.99%
- Clinical_Risk(Low_Risk) : 10.16%

Questo riscontro chiarisce un aspetto fondamentale del dominio modellato: la maggioranza dei fallimenti terapeutici (72.85%) non proviene da preparati ad alto rischio o formulazioni aggressive, bensì dalla fascia a rischio moderato. Si tratta prevalentemente di farmaci generici e terapie d'uso comune per disturbi ordinari, dove l'aspettativa del paziente è elevata ma l'efficacia percepita finisce per essere solo parziale.

Allo stesso tempo, la quota del 10.16% isola il principio diagnostico dell'*Explaining Away*: quando una cura appartenente alla classe a basso rischio fallisce, l'insuccesso non può essere imputato a complicanze o reazioni avverse gravi. Di conseguenza, il sistema diagnostico esclude il fattore della tossicità ed evidenzia che il fallimento è da ricondurre a una ridotta risposta individuale del paziente o a un'indicazione terapeutica iniziale non del tutto adeguata.

5.4 Apprendimento strutturale del grafo (Structure Learning)

Accanto alla formulazione manuale guidata dalla conoscenza medica di dominio, è stata condotta una procedura di apprendimento automatico della topologia di rete direttamente dai dati. Questo passaggio consente di verificare come un algoritmo puramente basato su evidenze statistiche organizzzi le dipendenze condizionate rispetto al DAG causale progettato a priori.

L'esplorazione dello spazio dei grafi orientati aciclici è stata eseguita mediante l'algoritmo euristico `HillClimbSearch`, ottimizzando il punteggio BIC per dati discreti (`bic-d`) con un vincolo di convergenza a 50 iterazioni. La ricerca ha restituito la seguente configurazione di archi:

- `Drug_Complexity` $\longrightarrow$ `Clinical_Risk`
- `Drug_Complexity` $\longrightarrow$ `Therapeutic_Area`
- `Drug_Complexity` $\longrightarrow$ `Toxicity_Tier`
- `Toxicity_Tier` $\longrightarrow$ `Clinical_Risk`
- `Toxicity_Tier` $\longrightarrow$ `Therapeutic_Area`
- `Clinical_Risk` $\longrightarrow$ `Therapeutic_Area`
- `Therapeutic_Area` $\longrightarrow$ `Target_Success`

Il confronto formale tra il grafo dell'esperto e la struttura estratta dai dati evidenzia una sola sovrapposizione esatta, ovvero l'arco ('`Drug_Complexity`', '`Clinical_Risk`'), facendo emergere chiare differenze interpretative tra causalità a priori e correlazione statistica:

- **Il nodo `Drug_Complexity` come driver primario:** l'algoritmo individua nella formulazione chimica (mono-principio rispetto ad associazioni fisse) una sorgente di varianza fondamentale, connettendola non solo a `Clinical_Risk`, ma anche a `Toxicity_Tier` e `Therapeutic_Area`. Dal punto di vista statistico, la presenza di più principi attivi polarizza fortemente sia il conteggio degli effetti collaterali sia la distribuzione delle patologie trattate, rendendo questo attributo un predittore robusto per l'intero sistema.
- **Riorientamento verso l'esito finale (`Therapeutic_Area` $\longrightarrow$ `Target_Success`):** mentre nel modello esperto l'area medica d'intervento agiva come causa a monte mediata dal rischio clinico, l'ottimizzatore BIC ha preferito collegarla direttamente alla variabile obiettivo `Target_Success`. Poiché alcune specialità (come l'oncologia o la dermatologia) presentano tassi di gradimento e soglie di tollerabilità intrinsecamente differenti, la metrica penalizzata trova conveniente associare direttamente l'area clinica al successo percepito, scavalcando la mediazione astratta introdotta dalla Knowledge Base.
- **Inversione dell'arco tra rischio e area:** l'algoritmo ha orientato l'arco da `Clinical_Risk` verso `Therapeutic_Area`. Trattandosi di un metodo non supervisionato guidato da criteri di informazione teorica (BIC), la ricerca euristica opera su classi di equivalenza, dove direzioni statisticamente equivalenti non riflettono necessariamente la sequenza temporale o causale del mondo reale.

Questo confronto convalida l'utilità dell'approccio ibrido tipico dei Knowledge-Based Systems: se l'apprendimento automatico da dati eccelle nell'individuare associazioni dirette e relazioni latenti non previste a tavolino (come l'influenza della complessità formulativa su tossicità e area clinica), l'integrazione del modello dell'esperto rimane indispensabile per evitare connessioni controintuitive.




Figura 12: DAG appreso automaticamente tramite algoritmo Hill-Climb Search.

Tabella 4: Confronto topologico tra il modello dell'esperto e la struttura appresa dai dati (Hill-Climb Search).

Sorgente (Padre)	Destinazione (Figlio)	Esperto	Dati	Stato Topologico
<i>Archi concordanti (Confermati)</i>				
Drug_Complexity	Clinical_Risk	✓	✓	Confermato da entrambi
<i>Archi a priori (Solo modello Esperto)</i>				
Therapeutic_Area	Clinical_Risk	✓	×	Non supportato statisticamente
Toxicity_Tier	Target_Success	✓	×	Mediato indirettamente
Clinical_Risk	Target_Success	✓	×	Dipendenza non diretta
<i>Relazioni scoperte (Solo apprendimento automatico)</i>				
Therapeutic_Area	Target_Success	×	✓	Nuova dipendenza diretta
Drug_Complexity	Therapeutic_Area	×	✓	Relazione latente
Drug_Complexity	Toxicity_Tier	×	✓	Relazione latente
Toxicity_Tier	Clinical_Risk	×	✓	Influenza sul rischio
Toxicity_Tier	Therapeutic_Area	×	✓	Correlazione inversa
Clinical_Risk	Therapeutic_Area	×	✓	Correlazione inversa

6 Conclusioni e sviluppi futuri

In questo progetto è stato sviluppato **KBS-PharmaRisk**, un sistema che unisce la conoscenza logica formale (ontologie e regole) con tecniche di machine learning e modelli probabilistici per analizzare un insieme di oltre 11.000 farmaci. L'obiettivo principale era verificare se l'aggiunta di regole ed etichette create a partire da un'ontologia potesse aiutare i modelli a prendere decisioni migliori rispetto all'uso dei soli dati grezzi. I risultati ottenuti hanno confermato questa ipotesi:

- **Miglioramento dei classificatori:** tutti i modelli testati su 10 run indipendenti hanno ottenuto prestazioni più alte quando sono state aggiunte le feature della Knowledge Base. Il caso più evidente è stato quello della Regressione Logistica, che con i soli dati grezzi non riusciva a distinguere la classe positiva (F1-score fermo al 5.45%), mentre con le nuove feature semantiche ha raggiunto il 40.12%, senza ricorrere a trucchi sui dati (*data leakage*).
- **Gestione dell'incertezza con la Rete Bayesiana:** l'uso del modello probabilistico ha permesso di andare oltre la semplice classificazione, consentendo di simulare scenari reali (come il calcolo del successo atteso per un farmaco oncologico o per una crema a basso impatto) e di fare ragionamenti a ritroso (*diagnostica inversa*) per capire da dove nascono i fallimenti delle terapie.
- **Confronto con l'apprendimento da dati:** il confronto tra la rete disegnata a mano e quella ricavata automaticamente con l'algoritmo Hill-Climb ha mostrato che i dati confermano l'importanza di variabili chiave come la complessità della formulazione, ma ha anche evidenziato come un algoritmo puramente statistico tenda a cercare scorciatoie dirette, dimostrando l'importanza di una guida logica a monte.

6.1 Sviluppi futuri

Il lavoro svolto lascia spazio a diversi miglioramenti che possono rendere il sistema ancora più preciso e completo:

1. Miglioramento dell'apprendimento e dei modelli predittivi:

- *Elaborazione migliore del testo:* nei dati di partenza, campi come gli usi clinici e gli effetti collaterali contengono molto testo libero. In futuro si potrebbero usare tecniche più avanzate di elaborazione del linguaggio naturale (NLP), come modelli di tipo BERT specializzati in ambito medico (ad esempio BioBERT), per estrarre informazioni più ricche e dettagliate da dare in pasto ai modelli.
- *Modelli più potenti:* oltre a quelli già provati (tra cui la rete neurale MLP), si potrebbero testare algoritmi basati su alberi potenziati come XGBoost o LightGBM, che di solito ottengono ottimi risultati su tabelle con variabili miste, cercando così di aumentare ulteriormente i valori di accuratezza ed F1-score.

2. Collegamento con i Linked Open Data (LOD):

l'ontologia creata in locale potrebbe essere collegata a database aperti del Web Semantico, come DBpedia, Wikidata o DrugBank. In questo modo il sistema potrebbe recuperare in automatico altre proprietà importanti dei medicinali (ad esempio la classe chimica esatta o le interazioni pericolose tra farmaci diversi) senza doverle inserire manualmente.

3. Evoluzione della Rete Bayesiana:

nella versione attuale le variabili continue sono state raggruppate in fasce discrete. Un passo avanti potrebbe essere l'uso di reti bayesiane ibride, capaci di gestire insieme numeri continui e classi discrete, evitando di perdere dettagli con la suddivisione in intervalli. Inoltre, durante l'apprendimento automatico della rete si potrebbero imporre dei vincoli obbligatori (ad esempio vietare collegamenti contrari alla logica medica), così da unire al meglio le evidenze dei dati con le regole cliniche.

In conclusione, il progetto ha dimostrato che combinare basi di conoscenza esplicite e apprendimento automatico è un approccio utile e concreto, soprattutto in ambiti delicati come quello medico dove la sola statistica grezza può non bastare per comprendere a fondo i problemi.